

修 士 学 位 論 文

題 目

タクシーの運転支援システム構築に関する研究

指 導 教 員

潮 俊光 教 授

報 告 者

広本 将基

平成 29 年 2 月 1 日

大阪大学基礎工学研究科
システム創成専攻社会システム数理領域
博士前期課程

概要

流しのタクシーが効率よく乗客を乗せるための運転支援システムの開発は、運転手の待遇改善につながる重要な課題である。本論文では、過去の乗車データと現在の流しのタクシーの分布から最適な進行方向を決定する方法を提案する。対象領域をいくつかの分割領域に分割し、各部分領域での需要予測をもとに部分領域ごとの流しのタクシーの変化を混合論理動的システムを使ってモデル化する。そして、モデル予測制御を応用して、各部分領域でのタクシーの最適移動分布を求める。実際に実装したソフトウェアを示す。

目次

概要	i
第 1 章 緒論	1
1.1 研究背景と目的	1
1.2 論文の構成	2
第 2 章 運転支援システムの説明	3
2.1 緒言	3
2.2 システム構成	3
2.3 結言	6
第 3 章 乗降車データに基づいた最適配車問題の定式化	7
3.1 緒言	7
3.2 タクシー移動モデル	7
3.3 モデル予測制御	13
3.3.1 定式化	13
3.3.2 実装結果	14
3.4 結言	15
第 4 章 結論	16
謝辞	17
参考文献	18
付録 A ニューラルネットワークの基礎	20

第 1 章

緒論

1.1 研究背景と目的

現在のタクシー業界は、高年齢化、低賃金、劣悪な労働環境という問題を抱えている。流しのタクシーが空車で走行する距離を減らすことで、賃金の向上が達成出来るだけでなく、CO2 排出量の削減にもつながる。現状では、運転手の経験と勘から流し走行をしており、経験の浅い運転手への流し運転の支援は重要な課題である。最近では、すべてのタクシーに GPS が装着されており、乗客を乗せた位置、一定走行時間・距離ごとの位置情報が無線でリアルタイムに会社へ送信されて、管理できるようになった。また、名古屋ではタクシーの自動運転による実証実験が行われている。こうした状況では、ビッグデータを活用して、顧客の発生予測をして、走行方向の支援を行うシステムを考えることは重要である。

一方、インテリジェント交通システムでは、自動車の走行データをオンラインでセンシングできるプローブカーを用いた交通状況のモニタリング法が開発されてきた¹。タクシーはプローブカーとして重要な役割を果たしているだけでなく、走行履歴から運転手の特性を推定することも可能となってきた²。さらに、携帯電話の位置情報や乗車履歴データから乗客の予測技術も急速に発達してきた^{3,4}。

タクシーの運行状況のモニタリング、乗客の予測技術の発展に伴い、最近、タクシーの最適配車の研究が注目されている。Seow 等は、乗客からの呼びに対して乗客の待ち時間が最小となるようなタクシーの配車法を提案している⁵。Qu 等は、空車で走行する距離の総和が最小になるような走行方法を提案している⁶。Miao 等は、モデル予測制御を用いた最適配車法を提案し、サンフランシスコの市街地を対象に実証実験を行っている⁷⁻⁹。

本論文では、まず、企業と共同開発したタクシー乗務員の運行をサポートするシステムの説明をする。そして、タクシーの移動モデルを混合論理動的システムでモデル化し、モデル予測

制御を応用した合理的な運行方法を提案する．提案モデルでは，個々のタクシーに対して個別の制御入力を行うのではなく，部分領域に分けられた中にあるタクシーに対しては同一の制御入力を行う．その点が文献⁷⁻⁹とは異なる点である．

1.2 論文の構成

本論文の構成について述べる．第 2 章では，企業と共同開発したタクシー運転支援システムの説明を行う．第 3 章では，支援システムで開発に取り組んだ，推奨される走行方向の導出を行う．タクシーが営業を行う領域をいくつかの部分領域（セル）に分割し，セル間でのタクシーの移動モデルを混合論理動的システムでモデル化する．そして，そのモデルを用いたモデル予測制御法を提案し，ソフトウェアへの実装結果を示す．最後に，第 4 章では結論と今後の課題について述べる．

第 2 章

運転支援システムの説明

2.1 緒言

本章では，タクシーの運転支援システムを実現するために，企業との共同開発で作成したソフトウェアのシステム構成について説明を行う．ソフトウェアはスマートフォン上で実行され，乗務員に提示される．スマホを利用することでタクシー事業者はカーナビを購入する経費を抑えられるメリットがある．一方，スマホの画面は小さいので，タクシーの乗務員が使いやすいように搭載する機能を選定する必要がある．

2.2 システム構成

図 2.1 は実際に作成されたアプリ画面である．アプリの主な使い方は以下のとおりである．まず，アプリを起動してアプリ上で提供される情報を参考にして流し営業を行い，乗客を乗せた場合は画面右上の緑のサークルをタップする．すると，サークルが赤色に変化し，アプリ上でのタクシーのステータスが空車から実車に変化する．乗客を下ろした場合は，もう一度サークルを押してタクシーのステータスを空車に戻す．アプリはタクシーのステータスが変化した場合と一定時間・距離走行した場合に位置情報とステータス情報をサーバーに送信する．

提供される情報は以下の 5 つである．1 つ目は営業領域内のイベント情報である．「yahoo! 路線情報」のサイトの HTML 記述の中からデータ抽出を行い電車の遅延情報を取得し，画面上部に表示する．電車の大幅な遅延が発生すると，タクシーやバスなどの他の公共交通機関を利用する人が確実に増えるため，この情報は重要である．2 つ目は過去の同曜日，同時刻付近に乗客を乗せた箇所を示すピン情報である．ピンの色は 3 種類あり，青，黄，赤の順に乗車時間が 10 分未満，10 分以上 20 分未満，20 分以上であった乗降車記録を示している．ピンが密

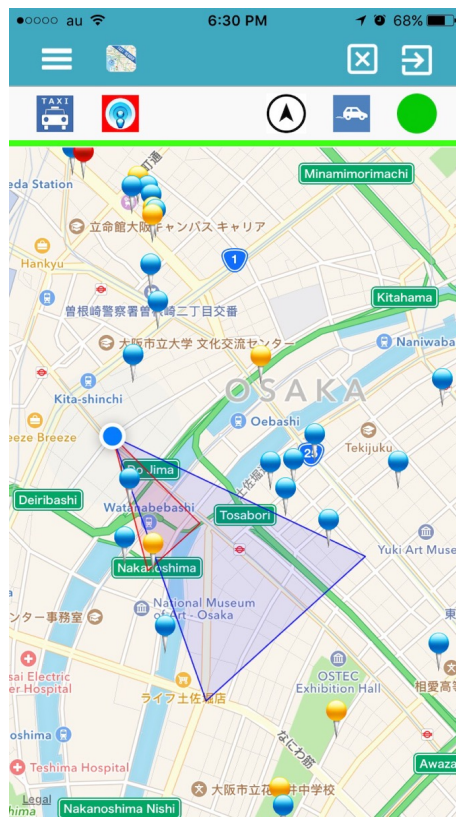


図 2.1: 乗務員が見るアプリ画面

集している箇所は乗客を獲得できる頻度が高いと言える．3 つ目は周囲で最もピンがある領域を示す方向を表す赤い三角形のオブジェクトである．マップを拡大表示して走行していた場合に，周囲のピンを見ることができなくなるので，必要な情報である．4 つ目は推奨される走行方向を表す青い三角形のオブジェクトである．すべてのタクシーが，ピンが集中している領域に利己的に集まると，それらの領域で供給過多が起きてしまい，全体として乗客獲得の機会を失ってしまう．そこで，ピンの情報と空車分布の情報を利用して推奨する走行方向をサーバー側で計算する．5 つ目は古典的なニューラルネットワークにより予測した需要の中で需要が多い箇所を表すサークルの情報である．雨が降るとタクシーを利用する人が増える．しかし，ピンの表示は気象条件を考慮していない．そこで，ニューラルネットワークの入力に天候や気温を含ませて，予測した需要の中で需要が多い箇所を表示することを考えた．

図 2.2 は 4 つ目の推奨される走行方向の情報を導き，各乗務員に提示する流れを図化したものである．本システムでは，各タクシーから走行データと乗降車データをリアルタイムに受け取り，データベースに保存する．表 2.1 は実際にデータベースに保存される乗降車データである．需要予測器では，表 2.1 の履歴データから乗客の発生分布を予測する．最適化器では，モ

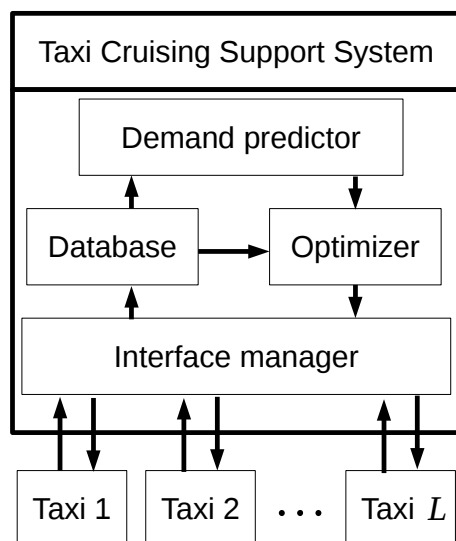


図 2.2: 流しタクシーの運転支援システム

表 2.1: データベースに保存される乗降車データ

乗車時刻	乗車緯度	乗車経度	降車時刻	降車緯度	降車経度
2016-11-06 02:18:08	34.66128	135.50286	2016-11-06 02:30:21	34.64936	135.51944
2016-11-06 02:40:40	34.66781	135.50914	2016-11-06 02:47:48	34.67094	135.53897
2016-11-06 03:03:59	34.66925	135.50633	2016-11-06 03:11:49	34.67011	135.50619

デル予測制御を用いて，この乗客予測と現在の空車のタクシーの分布から最適なタクシーの移動分布を求める．

5 つ目の情報を計算するためのニューラルネットワークは以下のような構成にした．入力層は 6 つの情報が入力される．1 つ目は月情報のための 4 個のノードである．1 年を春 (3 月から 5 月)，夏 (6 月から 8 月)，秋 (9 月から 11 月)，冬 (12 月から 2 月) の 4 つに分割して，春であれば春に割り当てられているノードのみに 1 が与えられ，それ以外のノードには 0 が与えられる．2 つ目は時刻情報のためのノードである．24 時間は 1440 分あるので 1440 個のノードを準備する．各時刻で対応するノードのみに 1 が与えられる．3 つ目は祝日であるかどうかのノードである．祝日であれば 1 が与えられ，そうでなければ 0 が与えられる．4 つ目は特別な日であるかどうかのノードである．大阪のタクシー業界における特別な日とは 5 日，10 日，20 日，月末のことである．タクシー事業者からの聞き取りで，これらの日は仕事でタクシーを利用する人が多く，それ以外の日と乗客数が異なることがわかったため，ノードに追加した．

5 つ目は天候に関するノードである．雨であれば 0 が与えられ，そうでなければ 1 が与えられる．6 つ目は気温に関する 2 つのノードである．その日の最高気温と最低気温を入力ノードに加えた．天候と気温の情報は気象庁のサーバーから XML 形式または JSON 形式のデータで利用可能だが，イベント情報の時と同様に，サイトの HTML 記述の中からデータ抽出を行った．入力層のノードの総数は 1449 個である．中間層は 1 層，ノード数は 200 個とした．出力層は，タクシーが営業を行う対象領域をいくつかの分割領域に分けた時に，それぞれの分割領域の需要数を予測するために分割領域の数のノードを用意した．

2.3 結言

本章では，提案するアプリケーションのシステム構成について説明を行った．乗務員には周辺のイベント情報と，過去に乗客を乗せた箇所を示すピン情報と，周辺で最もピンがある領域を示す方向と，推奨される進行方向と，古典的なニューラルネットワークにより予測した需要の中で需要が多い箇所を表すサークルの情報を示す．イベント情報や需要予測に用いる気象情報などはインターネット上から取得する．インターネット上には気象情報のように時間によって変化するデータが過去のものも含めて公開されている．データの形式は XML 形式や JSON 形式のようにプログラムからの利用を考慮したものや，HTML 記述のものもある．気象庁や国土交通省のような公的な機関が提供するデータだけではなく，SNS などの手段を利用して得られたリアルタイムな情報をイベント情報として提供することも考えられる．また，需要予測器として古典的なニューラルネットワークを利用したが，学習データにスパーク性があるため過学習を起こす問題がある．多変量時系列モデルのような他の予測方法もあるため，タクシー運転支援システムの実装に適した需要予測の方法を見つけることが，今後の研究課題である．

第 3 章

乗降車データに基づいた最適配車問題の定式化

3.1 緒言

本章では，タクシーが営業を行う領域をいくつかの部分領域（以下セルと呼ぶ）に分割し，セル間でのタクシーの移動モデルを混合論理的動的システムでモデル化する．そして，そのモデルを用いたモデル予測制御法を提案し，アプリケーションへの実装結果を示す．

3.2 タクシー移動モデル

対象領域を N 個のセルに分割する．時刻 k のときのセル i ($i = 1, 2, \dots, N$) での空車数を $x_i(k)$ とおき，対象領域内のタクシーの実車数を $r(k)$ とおく．時刻 k でのセル i で空車の実車に変化するタクシー数を $s_i(k)$ とおく．すなわち，時間区間 $[k, k+1)$ の間に，セル i で空車から実車になるタクシー数が $s_i(k)$ である．時刻 k でのセル i で実車が空車に変化するタクシー数を $e_i(k)$ とおく．さらに入力として，時刻 k でのセル i からセル j へ移動する空車数を $u_{i,j}(k)$ とおく．つまり， $x_i(k)$ と $r(k)$ が時刻 k におけるシステムの状態量を表し， $s_i(k)$ と $e_i(k)$ と $u_{i,j}(k)$ が時刻 $k+1$ の状態量を記述するための変動量を表している．このとき，各セルの空車数のダイナミクスは

$$x_i(k+1) = x_i(k) - s_i(k) + e_i(k) + \sum_{j=1}^N \left(u_{j,i}(k) - u_{i,j}(k) \right) \quad (3.1)$$

となる．また，実車数のダイナミクスは

$$r(k+1) = r(k) + \sum_{i=1}^N \left(s_i(k) - e_i(k) \right) \quad (3.2)$$

となる．

ここで，式 (3.1)，(3.2) から

$$\begin{aligned} & r(k+1) + \sum_{i=1}^N x_i(k+1) \\ &= \left(r(k) + \sum_{i=1}^N \left(s_i(k) - e_i(k) \right) \right) + \sum_{i=1}^N \left(x_i(k) - s_i(k) + e_i(k) + \sum_{j=1}^N \left(u_{j,i}(k) - u_{i,j}(k) \right) \right) \\ &= r(k) + \sum_{i=1}^N x_i(k) + \sum_{i=1}^N \sum_{j=1}^N \left(u_{j,i}(k) - u_{i,j}(k) \right) \\ &= r(k) + \sum_{i=1}^N x_i(k) + \sum_{i=1}^N \sum_{j=1}^N \left(u_{i,j}(k) - u_{i,j}(k) \right) \\ &= r(k) + \sum_{i=1}^N x_i(k) \end{aligned}$$

が示せる．すなわち，タクシーの総数は変化しない．タクシーの総数を L とおくと

$$r(k) = L - \sum_{i=1}^N x_i(k) \quad (3.3)$$

の関係が成り立つ．

実車に変化するタクシー数 $s_i(k)$ については以下のように考える．まず，時刻 k での制御入力に従って移動してから実車になりうるとする．このとき，時間区間 $[k, k+1)$ の間で実車から空車になるタクシーもすぐに実車になりうるので，時間区間 $[k, k+1)$ の間にセル i にいる実車になりうるタクシーの台数は $e_i(k) + \sum_{j=1}^N u_{j,i}(k)$ であり，実車になる台数はこの数を超えることはないので，

$$h_i(k) = e_i(k) + \sum_{j=1}^N u_{j,i}(k) - \alpha_i d_i(k) \quad (3.4)$$

とおくと，

$$s_i(k) = \begin{cases} \alpha_i d_i(k) & \text{if } h_i(k) \geq 0 \\ h_i(k) + \alpha_i d_i(k) & \text{otherwise} \end{cases} \quad (3.5)$$

と表される．ただし， α_i はセル i においてタクシーに乗車できる乗客の割合である．つまり，領域内に乗客と空車のタクシーがいる状況でも，乗客を見つけることが出来ず，実車に変化できない場合を考慮したモデルになっている．この定数 α_i は，過去のデータから推定することができる． $d_i(k)$ は時間区間 $[k, k+1)$ の間にセル i で乗車できなかった客数であり，

$$d_i(k+1) = d_i(k) - s_i(k) + p_i(k) \quad (3.6)$$

と表される．ただし， $p_i(k)$ は時間区間 $[k, k+1)$ の間で発生する新たな乗客数で，過去の乗車データから予測される．

空車に変化するタクシー数 $e_i(k)$ は

$$e_i(k) = \beta_i r(k) \quad (3.7)$$

とする．ただし， β_i は実車全体の中でセル i で空車になる割合である．この定数 β_i は，過去のデータから推定することができる．

ここで，入力に関する制約として，各セル i について

$$x_i(k) = \sum_{j=1}^N u_{i,j}(k) \quad (3.8)$$

を与える．このことは，各セルにおいて時刻 k での空車をどこに移動させるかを決定し，それに沿って，空車が移動すると仮定していることになる．空車は制御入力に従って移動してから実車に変化できると仮定する．このように移動する空車数を定めると，式 (3.1)，(3.8) から，各空車数のダイナミクスは

$$x_i(k+1) = e_i(k) - s_i(k) + \sum_{j=1}^N u_{j,i}(k) \quad (3.9)$$

となる．さらに，自動車の移動速度の制約から必ず 0 になる $u_{i,j}(k)$ がある．例えば，時間単位で隣接するセルにしか移動できない場合には，セル i に隣接しないセル ℓ については

$$u_{i,\ell}(k) = 0 \quad \forall k \quad (3.10)$$

とおく．

以上より，タクシー移動モデルは以下ようになる．

$$x_i(k+1) = e_i(k) - s_i(k) + \sum_{j=1}^N u_{j,i}(k) \quad (3.11)$$

$$r(k) = L - \sum_{i=1}^N x_i(k) \quad (3.12)$$

$$e_i(k) = \beta_i r(k) \quad (3.13)$$

$$s_i(k) = \begin{cases} \alpha_i d_i(k) & \text{if } h_i(k) \geq 0 \\ h_i(k) + \alpha_i d_i(k) & \text{otherwise} \end{cases} \quad (3.14)$$

$$d_i(k+1) = d_i(k) - s_i(k) + p_i(k) \quad (3.15)$$

$$h_i(k) = e_i(k) + \sum_{j=1}^N u_{j,i}(k) - \alpha_i d_i(k) \quad (3.16)$$

$$x_i(k) = \sum_{j=1}^N u_{i,j}(k) \quad (3.17)$$

$$u_{i,\ell}(k) = 0 \quad \text{if セル } i \text{ からセル } j \text{ に移動不可能} \quad (3.18)$$

ここで，式 (3.14) が条件付きの式になっている．この式は以下のように変形すれば，システム全体は混合論理的動的システムになる^{10,11}．

まず，以下の論理変数 $\delta_i(k) \in \{0, 1\}$ を導入する．

$$\delta_i(k) = \begin{cases} 1 & \text{if } h_i(k) \geq 0 \\ 0 & \text{otherwise} \end{cases} \quad (3.19)$$

と定義する．このとき，制約条件式 (3.19) は次の不等式制約条件になる¹⁰．

$$h_i^{\inf}(k)(1 - \delta_i(k)) \leq h_i(k) \leq h_i^{\sup}(k)\delta_i(k) + (\delta_i(k) - 1)\epsilon_i(k) \quad (3.20)$$

ただし， $h_i^{\inf}(k), h_i^{\sup}(k) \in \mathbb{R}$ は $h_i(k)$ の引数を取りうる任意の値に対して $h_i^{\inf}(k) \leq h_i(k) \leq h_i^{\sup}(k)$ であり， $\epsilon_i(k) \in \mathbb{R}_{++}$ は十分に小さな正の実数である．実際に，式 (3.20) は $\delta_i(k) = 1$ のときは

$$0 \leq h_i(k) \leq h_i^{\sup}(k)$$

となり， $\delta_i(k) = 0$ のときは

$$h_i^{\inf}(k) \leq h_i(k) \leq -\epsilon_i(k) (< 0)$$

となるので， $\epsilon_i(k)$ の値を十分に小さくすれば，任意の精度で制約条件式を不等式制約式に変換可能であることが確認できる．また，初期時刻を $k = t$ とおくと， $k > t$ の $h_i(k)$ について式 (3.15) から以下の不等式が成り立つ．

$$\begin{aligned}
h_i(k) &= e_i(k) + \sum_{j=1}^N u_{j,i}(k) - \alpha_i d_i(k) \\
&\geq -\alpha_i d_i(k) \\
&= -\alpha_i \left(d_i(k-1) - s_i(k-1) + p_i(k-1) \right) \\
&\geq -\alpha_i \left(d_i(k-1) + p_i(k-1) \right) \\
&\geq -\alpha_i \left(d_i(k-2) + p_i(k-2) + p_i(k-1) \right) \\
&\geq \dots \\
&\geq -\alpha_i \left(d_i(t) + \sum_{c=t}^{k-1} p_i(c) \right) \\
h_i(k) &\leq e_i(k) + \sum_{j=1}^N u_{j,i}(k) \\
&\leq L
\end{aligned}$$

したがって， $h_i(k)$ の上界と下界を以下のように定める．

$$h_i^{\sup}(k) = L \quad (3.21)$$

$$h_i^{\inf}(k) = -\alpha_i \left(d_i(t) + \sum_{c=t}^{k-1} p_i(c) \right) \quad (3.22)$$

論理変数 $\delta_i(k)$ を用いることで式 (3.14) は以下のように変形できる．

$$\begin{aligned}
s_i(k) &= \delta_i(k) \alpha_i d_i(k) + (1 - \delta_i(k)) (h_i(k) + \alpha_i d_i(k)) \\
&= -\delta_i(k) h_i(k) + h_i(k) + \alpha_i d_i(k)
\end{aligned} \quad (3.23)$$

ここで，

$$z_i(k) = \delta_i(k) h_i(k) \quad (3.24)$$

とおくと，式 (3.23) は

$$s_i(k) = -z_i(k) + h_i(k) + \alpha_i d_i(k) \quad (3.25)$$

となる．式 (3.24) は次の不等式制約条件になる¹¹．

$$h_i^{\inf}(k)\delta_i(k) \leq z_i(k) \leq h_i^{\sup}(k)\delta_i(k) \quad (3.26)$$

$$h_i(k) - h_i^{\sup}(k)(1 - \delta_i(k)) \leq z_i(k) \leq h_i(k) - h_i^{\inf}(k)(1 - \delta_i(k)) \quad (3.27)$$

以上より，初期時刻を $k = t$ とおくと，タクシー移動モデルは以下の混合論理動的システムで記述される．

$$x_i(k+1) = e_i(k) - s_i(k) + \sum_{j=1}^N u_{j,i}(k) \quad (3.28)$$

$$r(k) = L - \sum_{i=1}^N x_i(k) \quad (3.29)$$

$$e_i(k) = \beta_i r(k) \quad (3.30)$$

$$h_i^{\inf}(k)(1 - \delta_i(k)) \leq h_i(k) \leq h_i^{\sup}(k)\delta_i(k) + (\delta_i(k) - 1)\epsilon_i(k) \quad (3.31)$$

$$s_i(k) = -z_i(k) + h_i(k) + \alpha_i d_i(k) \quad (3.32)$$

$$h_i^{\inf}(k)\delta_i(k) \leq z_i(k) \leq h_i^{\sup}(k)\delta_i(k) \quad (3.33)$$

$$h_i(k) - h_i^{\sup}(k)(1 - \delta_i(k)) \leq z_i(k) \leq h_i(k) - h_i^{\inf}(k)(1 - \delta_i(k)) \quad (3.34)$$

$$h_i^{\sup}(k) = L \quad (3.35)$$

$$h_i^{\inf}(k) = -\alpha_i \left(d_i(t) + \sum_{c=t}^{k-1} p_i(c) \right) \quad (3.36)$$

$$d_i(k+1) = d_i(k) - s_i(k) + p_i(k) \quad (3.37)$$

$$h_i(k) = e_i(k) + \sum_{j=1}^N u_{j,i}(k) - \alpha_i d_i(k) \quad (3.38)$$

$$x_i(k) = \sum_{j=1}^N u_{i,j}(k) \quad (3.39)$$

$$u_{i,\ell}(k) = 0 \quad \text{if セル } i \text{ からセル } j \text{ に移動不可能} \quad (3.40)$$

3.3 モデル予測制御

3.3.1 定式化

節 3.2 で導出したタクシー移動モデルをもとに，時刻 t において以下の有限区間最適制御問題を考える．ただし， T は正の整数である．

$$\text{minimize } J_t = \sum_{i=1}^N d_i(t+T) \quad (3.41)$$

制約条件：各 $i = 1, 2, \dots, N$ と $k = t, t+1, \dots, t+T-1$ について

$$x_i(k+1) = e_i(k) - s_i(k) + \sum_{j=1}^N u_{j,i}(k) \quad (3.42)$$

$$r(k) = L - \sum_{i=1}^N x_i(k) \quad (3.43)$$

$$e_i(k) = \beta_i r(k) \quad (3.44)$$

$$h_i^{\inf}(k)(1 - \delta_i(k)) \leq h_i(k) \leq h_i^{\sup}(k)\delta_i(k) + (\delta_i(k) - 1)\epsilon_i(k) \quad (3.45)$$

$$s_i(k) = -z_i(k) + h_i(k) + \alpha_i d_i(k) \quad (3.46)$$

$$h_i^{\inf}(k)\delta_i(k) \leq z_i(k) \leq h_i^{\sup}(k)\delta_i(k) \quad (3.47)$$

$$h_i(k) - h_i^{\sup}(k)(1 - \delta_i(k)) \leq z_i(k) \leq h_i(k) - h_i^{\inf}(k)(1 - \delta_i(k)) \quad (3.48)$$

$$h_i^{\sup}(k) = L \quad (3.49)$$

$$h_i^{\inf}(k) = -\alpha_i \left(d_i(t) + \sum_{c=t}^{k-1} p_i(c) \right) \quad (3.50)$$

$$d_i(k+1) = d_i(k) - s_i(k) + p_i(k) \quad (3.51)$$

$$h_i(k) = e_i(k) + \sum_{j=1}^N u_{j,i}(k) - \alpha_i d_i(k) \quad (3.52)$$

$$x_i(k) = \sum_{j=1}^N u_{i,j}(k) \quad (3.53)$$

$$u_{i,\ell}(k) = 0 \quad \text{if セル } i \text{ からセル } j \text{ に移動不可能} \quad (3.54)$$

$$x_i(t) = \text{given} \quad (3.55)$$

$$d_i(t) = \text{given} \quad (3.56)$$



図 3.1: 最適方向の時間的变化 (2016 年 3 月 31 日)

自明なものも含めると，変数の数は $N^2T + 6NT + 2N + T$ ，制約条件の数は $10NT + 2N$ である．制約条件は線形の式であり，変数が実数と整数のどちらもあるので，求める最適化問題は混合整数計画問題として定式化できる．コスト関数 (3.41) は各時刻 t において，時刻 $t + T$ での乗車できない乗客数の総和を最小にすることを意味する．

3.3.2 実装結果

アプリケーション上に実装した結果を示す．対象領域は大阪駅から難波あたりまでとし，一辺の長さ 2km の正方形のセルを使って，東西に 6 セル，南北に 4 セルに分割した ($N=24$)．過去の乗降車データからは乗車率 α_i を推定できないため，すべてのセルにおいて乗車率 $\alpha_i = 0.9$ とした．2 分を 1 時間単位として，2 時間単位区間 ($T=2$) でモデル予測制御により最適移動分布を計算した．図 3.1 に運転手に提示する画面の時間変化を示す．青色の方向が推奨する最適な方向，すなわち，最適化問題を解くことで得られた，移動するタクシー数が最大となる方向である．ピンは，過去の 4 週間の同曜日の同時刻から 2 分前から 4 分後までに乗客を乗せた場所を表す．1 辺の長さ 200m の正方形のセルで分割された対象領域の，3km 範囲内のセルの中で最も乗車数が多いセルを赤色の方向（以下，貪欲な方向と呼ぶ）が示している．18 時 2 分から 15 分までは，最適な方向と貪欲な方向が異なっており，18 時 24 分にはほぼ同じ方向を示している．最多乗車データのある領域セルが必ずしも最適な方向であるとは限らないことがわかる．これは，最多乗車データのあるセル周辺に多くの空車タクシーがいる場合には，むしろタクシーを分散させて，対象領域全体として乗客の獲得を図るような最適移動分布を求めているからである．

3.4 結言

本章では、流しのタクシーの走行支援を目的とした最適移動分布を求める方法を提案した。対象領域をいくつかの分割領域（セル）に分割し、各セル間のタクシーの移動を表すマクロモデルを混合論理動的システムを用いて表し、モデル予測制御によって最適な移動分布を求めた。大阪駅から難波までを対象領域として実データをもとに最適な移動方向分布を計算した結果を示した。乗客数が多いと予想される方向と最も好ましい移動方向とが必ずしも一致しなかった。このことから、対象領域全体の予測乗客分布と流しのタクシーの現在の分布をもとにして支援を行うことが重要であることがわかる。

今回の実験では、各セルの一辺の長さを 2km とした。また、1 時間単位に進むことができるセルは隣接するセルのみとした。長さを短くし、隣接するセル以外にも空車が移動できるようにすれば、より精度よく最適移動方向を計算できるが、計算時間が急速に増大する。計算の並列化、最適解の近似などによる計算時間の短縮が、今後の研究課題である。

第 4 章

結論

本論文では，タクシーの走行を支援するシステムを提案し，実装を行った結果を示した．タクシーの移動モデルを混合論理動的システムを用いて表し，モデル予測制御を応用して混合整数計画問題を解くことで空車タクシーの最適移動分布を求める方法である．実装にあたっては，大阪のタクシー事業者から実データをいただき，実際の空車分布から実証実験を行った．

今後の課題としては，混合整数計画問題の計算の並列化，最適解の近似などによる計算時間の短縮が挙げられる．

現在，車の自動運転に関して多くの研究が行われている．いずれ，タクシーの自動運転が実用化される可能性があるため，タクシーの最適配車問題は今後も様々な研究がなされていくと考える．本研究が，これらの研究の発展に寄与することを期待する．

謝辞

本研究を行うにあたり，懇切丁寧なご指導，ご教授を賜りました大阪大学大学院基礎工学研究科システム創成専攻 潮 俊光 教授に心より感謝の意を表します．

また，さまざまな面において励ましや助言をいただきました潮研究室の皆様に深く感謝いたします．

参考文献

- [1] 山本俊行, K. Liu, 森川高行, “ タクシー配車データのプローブデータとしての活用に関する基礎的分析,” 土木計画学研究・論文集, Vol. 23, No. 4, pp. 863-870, 2006.
- [2] 金月寛彰, 服部宏充, “ プローブカーデータを利用したタクシードライバーの個人特性の分析とモデル化,” 第 29 回人工知能学会全国大会, 演題番号 1N4-4, 2015.
- [3] K. Zhao, S. Tarkoma, S. Liu, and H. Vo, “ Urban HumaMobility Data Mining: An Overview,” in Proc. 2016 IEEE International Conference on Big Data, 2016.
- [4] K. Zhao, D. Khryashchev, J. Freire, C. Silva, and H. Vo, “ Predicting Taxi Demand at High Spatial Resolution: Approaching the Limit of Predictability,” in Proc. 2016 IEEE International Conference on Big Data, 2016.
- [5] K. T. Seow, N. H. Dang, and D.-H. Lee, “ A Collaborativ Multiagent Taxi-Dispatch System,” IEEE Trans. Automation Science and Engineering, Vol. 7, No. 3, pp. 607-616, 2010.
- [6] M. Qu, H. Zhu, J. Liu, G. Liu, and H. Xiong, “ A CostEffective Recommender System for Taxi Drivers,” in Proc. 20th International Conference on KDD, pp. 45-54, 2014.
- [7] F. Miao, S. Lin, S. Munir, J. A. Stankovic, H. Huang, D. Zhang, T. He, G. J. Pappas, “ Dispatch with Real-Time Sensing Data in Metropolitan Areas - A Receding Horizon Control Approach,” in Proc. International Conference on Cyber-Physical Systems, pp. 100-109, 2015.
- [8] F. Miao, S. Han S. Lin, and G. J. Pappas, “ Robust Tax Dispatch under Model Uncertainties,” in Proc. 54th IEEE Conference on Decision and Control, pp. 2816-2821, 2015.
- [9] F. Miao, S. Han, S. Lin, Q. Wang, J. Stankovic, A. Hendawi, D. Zhangm T. He, and G. Pappas, “ Data-Driven Robust Taxi Dispatch under Demand Uncertainties,” arXiv:1603.06263, 2016.

- [10] A. Bemporad and M. Morari, "Control of Systems Integrating Logic, Dynamics, and Constraints," *Automatica*, Vol. 35, No. 3, pp. 407-427, 1999.
- [11] 井村順一, 東俊一, 増淵泉, *ハイブリッドシステムの制御*, コロナ社, 2014.
- [12] 中野 良平, *ニューラル情報処理の基礎数理*, 数理工学社, 2005.
- [13] C. Bishop, 元田他監訳, *パターン認識と機械学習 (上, 下)*, 丸善出版, 2008.
- [14] 神嶋敏弘, *深層学習*, 近代科学社, 2015.
- [15] F. Rosenblatt, "The Perceptron: a probabilistic model for information storage and organization in the brain," *Psychological Review*, Vol. 65, No. 6, pp. 386-408, 1958.
- [16] G. Cybenko, "Approximation by superpositions of a sigmoidal function," *Mathematics of Control, Signals, and Systems*, Vol. 2, No. 4, pp. 303-314.
- [17] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, "Learning representations by back-propagating errors," *Nature*, Vol. 323, No. 9, pp. 533-536, 1986.

付録 A

ニューラルネットワークの基礎

ニューラルネットワークは、動物の脳神経系を模倣した情報処理の数理モデルである¹²⁻¹⁴。本節では、入力に対して確定的に出力が決まる階層型ニューラルネットワークの数理モデルについて説明を行う。

階層型ニューラルネットワークは多層パーセプトロンとよばれ、単純パーセプトロンを層状に繋ぎあわせた構造をしている。単純パーセプトロンは Rosenblatt が提案した情報処理モデルである¹⁵。図 A.1 に例を示す。単純パーセプトロンでは、多次元の入力 $\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ に対する出力 $y \in \mathbb{R}$ を以下のように計算する。

$$y = a\left(\sum_{i=1}^n w_i x_i - \theta\right) \quad (\text{A.1})$$

$$a(t) = \begin{cases} 1 & \text{if } t \geq 0 \\ 0 & \text{otherwise} \end{cases} \quad (\text{A.2})$$

ただし、 $w_i \in \mathbb{R}$ は第 i 番目の入力要素 x_i に対する結合の重みである。 $\theta \in \mathbb{R}$ はしきい値である。関数 $a(\cdot)$ は単純パーセプトロンの活性化関数や出力関数と呼ばれる。ここで、常に 1 の値をとるダミー変数 x_0 を導入して、 $\mathbf{x} = (x_0, \dots, x_n)$ 、 $\mathbf{w} = (w_0, \dots, w_n)$ とすれば、式 (A.1) は

$$y = a\left(\sum_{i=0}^n w_i x_i\right) = a(\mathbf{w}^T \mathbf{x}) \quad (\text{A.3})$$

となる。ただし、 $w_0 = -\theta$ である。

図 A.2 に 4 層からなる多層パーセプトロンの例を示す。この例では、入力層に入力された信号 \mathbf{x} は途中 2 つの中間層を経て出力層に伝播している。各層の単純パーセプトロン（以下ノードと呼ぶ）では、式 (A.1) に従って信号が変換される。ただし、入力層のノードは入力信号をそのまま出力するので、 $y_i^{(1)} = x_i$ である。多層パーセプトロンの第 n 層の第 k ノードが




図 A.1: 単純パーセプトロンの例




図 A.2: 多層パーセプトロンの例

ら第 $n + 1$ 層の第 j ノードへの結合の重みを $w_{k,j}^{(n+1)}$ とする．ネットワークの中の結合の重みをすべてまとめて $W = \{w_{k,j}^n\}$ と書くと，多層パーセプトロンの出力は $y = g(x, W)$ のように入力ベクトルと結合の重みによって決まる．また，Cybenko は中間層の活性化関数が

$$a(t) = \begin{cases} 1 & \text{as } t \rightarrow \infty \\ 0 & \text{as } t \rightarrow -\infty \end{cases} \quad (\text{A.4})$$

の性質を持つ非線形の連続な単調増加関数であり，出力層の活性化関数が線形関数であるとき，中間層が 1 層の多層パーセプトロンによって任意の連続関数が関数 g によって近似可能であることを示している¹⁶．

最後に、多層パーセプトロンの重みの学習方法のひとつである誤差逆伝播学習について説明する¹⁷。誤差逆伝播学習法では、ノードの活性化関数として微分可能な関数を用いる。ここでは、式 (A.6) のシグモイド関数を用いた場合の説明をする。

$$a(t) = \text{sig}(t) = \frac{1}{1 + e^{-t}} \quad (\text{A.5})$$

多層パーセプトロンの層の数は N とし、学習用のデータとして入力 x と正解の出力 r を与える。学習のための評価基準として、出力層での誤差評価、例えば二乗誤差を用いることにする。

$$E(W) = \frac{1}{2} \sum_{j=1}^{K_N} (r_j - y_j^{(N)})^2 \quad (\text{A.6})$$

活性化関数は微分可能なものを仮定しているので、誤差評価 $E(W)$ への結合の重み $w_{k,j}^n$ の寄与を $E(W)$ の偏微分係数として計算することができる。つまり、勾配降下法により、出力と正解のデータとの誤差が小さくなるように、すべての結合の重みを更新することができる。例えば、確率的勾配降下法による結合の重みの更新は以下ようになる。

$$\begin{aligned} w_{k,j}^{(n+1)} &\leftarrow w_{k,j}^{(n+1)} - \eta \frac{\partial E(W)}{\partial w_{k,j}^{(n+1)}} \\ &= w_{k,j}^{(n+1)} - \eta \delta_j^{(n+1)} y_k^{(n)} \end{aligned} \quad (\text{A.7})$$

ただし、 η は学習率である。式 (A.7) の中にある $\delta_j^{(n+1)}$ は以下の式で求められる。

$$\delta_j^{(N)} = -(r_j - y_j^{(N)}) y_j^{(N)} (1 - y_j^{(N)}) \quad (\text{A.8})$$

$$\delta_j^{(n)} = \left\{ \sum_{k=1}^{K_{n+1}} \delta_j^{(n+1)} w_{k,j}^{(n+1)} \right\} y_j^{(n)} (1 - y_j^{(n)}) \quad (\text{A.9})$$

$\delta_j^{(n+1)}$ の計算過程を見ると、出力層での誤差を前の層に伝播させていく形になっている。このことが誤差逆伝播学習の名前の由来である。

付録 B

混合論理動的システム

混合論理動的システム (以下 MLD システムと呼ぶ) モデルは

$$\begin{cases} x(k+1) = Ax(k) + B_1u(k) + B_2z(k) + B_3\delta(k) \\ Cx(k) + D_1u(k) + D_2z(k) + D_3\delta(k) \leq D_4 \end{cases} \quad (\text{B.1})$$

で与えられる¹¹ . ここで $x(k) \in \mathbb{R}^n$ は状態, $u(k) \in \mathbb{R}^m$ は入力, $z(k) \in \mathbb{R}^{l_1}$ と $\delta(k) \in \{0, 1\}^{l_2}$ は補助変数である . また, $A \in \mathbb{R}^{n \times n}$, $B_1 \in \mathbb{R}^{n \times m}$, $B_2 \in \mathbb{R}^{n \times l_1}$, $B_3 \in \mathbb{R}^{n \times l_2}$, $C \in \mathbb{R}^{q \times n}$, $D_1 \in \mathbb{R}^{q \times m}$, $D_2 \in \mathbb{R}^{q \times l_1}$, $D_3 \in \mathbb{R}^{q \times l_2}$, $D_4 \in \mathbb{R}^q$ は定数行列である . 補助変数 δ は, このモデルの離散状態を表している .

バイナリ変数と論理積, 論理和, 否定などの論理演算を含む命題論理は, バイナリ変数と四則演算からなる線形不等式で表現できる . 例えば, 命題 i の真偽を表す変数を論理変数と呼び, $X_i \in \{0, 1\}$ で表す . そして, X_i を命題「 $\delta_i = 1$ である」と対応付け, $X_i = [\delta_i = 1]$ と表現することにする . すると, 各論理演算について以下の補題が成り立つ .

補題 B.1

1. $[\delta_1 = 1] \vee [\delta_2 = 1] (= X_1 \vee X_2)$ と $\delta_1 + \delta_2 \geq 1$ は等価である .
2. $[\delta_1 = 1] \wedge [\delta_2 = 1] (= X_1 \wedge X_2)$ と $\delta_1 = 1, \delta_2 = 1$ は等価である .
3. $[\delta_1 = 1] \rightarrow [\delta_2 = 1] (= X_1 \rightarrow X_2)$ と $\delta_1 - \delta_2 \leq 0$ は等価である .
4. $[\delta_1 = 1] \leftrightarrow [\delta_2 = 1] (= X_1 \leftrightarrow X_2)$ と $\delta_1 - \delta_2 = 0$ は等価である .
5. $[\delta_1 = 1] \oplus [\delta_2 = 1] (= X_1 \oplus X_2)$ と $\delta_1 + \delta_2 = 1$ は等価である .

ただし, $\vee, \wedge, \rightarrow, \leftrightarrow, \oplus$ は, それぞれ, 論理和, 論理積, 否定, 含意, 等価, 排他的論理和である .

最後に本論文で利用した, 連続値変数を含む場合の論理条件の不等式表現について補題を示

す .

補題 B.2 $\delta \in \{0, 1\}$ をインデックス変数 , $x \in \mathbb{R}^n$ を連続値変数とする . このとき , 関数 $h : \mathbb{R}^n \rightarrow \mathbb{R}$, $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$ に対して , 有界集合 $\mathbb{X} \subset \mathbb{R}^n$ 上で次の関係が成り立つ .

1. $[\delta_1 = 1] \leftrightarrow [h(x) \geq 0]$ は , つぎの線形不等式によって任意の精度で近似できる .

$$h_{\inf}(1 - \delta) \leq h(x) \leq h_{\sup}(\delta - 1)\epsilon \quad (\text{B.2})$$

ただし , $h_{\inf}, h_{\sup} \in \mathbb{R}$ はすべての $x \in \mathbb{X}$ に対して $h_{\inf} \leq h(x) \leq h_{\sup}$ を満たすものであり , $\epsilon \in \mathbb{R}_{++}$ は任意に選ばれた十分小さい定数である .

2. $z = \delta g(x)$ はつぎの不等式と等価である .

$$g_{\inf}\delta \leq z \leq g_{\sup}\delta \quad (\text{B.3})$$

$$g(x) - g_{\sup}(1 - \delta) \leq z \leq g(x) - g_{\inf}(1 - \delta) \quad (\text{B.4})$$

ただし , $g_{\inf}, g_{\sup} \in \mathbb{R}^m$ はすべての $x \in \mathbb{X}$ に対して $g_{\inf} \leq g(x) \leq g_{\sup}$ を満たすベクトルである .

研究業績

国際会議

- Masaki Hiromoto and Toshimitsu Ushio, “Learning an Optimal Control Policy for a Markov Decision Process Under Linear Temporal Logic Specifications,” in Proceedings of 2015 IEEE Symposium on Adaptive Dynamic Programming and Reinforcement Learning (in 2015 IEEE Symposium Series on Computational Intelligence), Cape Town, South Africa, pp. 548-555, Dec. 2015.
- Toshimitsu Ushio, Masaki Hiromoto, Akiyoshi Okamoto, and Tomoaki Akiyama, “WIP Abstract: A Mixed Logical Dynamical System Model for Taxi Cruising Support System,” In Proceedings of 2016 ACM/IEEE 7th International Conference on Cyber-Physical Systems Vienna, Austria April 2016.

国内会議

- 広本 将基, 潮 俊光, 「LTL 制約の下での MDP に対するスーパーバイザの強化学習」, 2016 年電子情報通信学会総合大会, p. 166, 2016.
- 広本 将基, 潮 俊光, 岡本 明義, 秋山 友昭, 「モデル予測制御によるタクシーの最適配車問題の定式化」, 電子情報通信学会技術報告書, MSS2016-76, SS2016-55, pp. 113-116, 2017.